isec
Politécnico de Coimbra

TRAFFIC SIGNALS CLASSIFICATION

INTELIGÊNCIA COMPUTACIONAL

2024/2025
João Pedro Silveira da Costa, N.º 2022143368
Juliana Silva Teixeira, N.º 2022143370

ÍNDICE

1. DESCRIÇÃO DO PROBLEMA

Desenvolver um modelo de classificação de imagens de sinais de trânsito utilizando uma rede neural convolucional (CNN), com foco em sistemas de monitoramento e assistência ao condutor.

Desafios:

- Processar imagens de diferentes condições de iluminação, ângulos e qualidade.
- Garantir alta precisão e eficiência na classificação de sinais de trânsito, que apresentam variações visuais significativas.

Objetivos:

- Criar uma solução robusta para identificar sinais de trânsito em tempo real.
- Otimizar o desempenho do modelo ajustando hiperparâmetros e testando diferentes estruturas de rede.

Métricas de Avaliação:

- Accuracy, precision, recall, F1-score e AUC para avaliar a performance do modelo.

Impacto:

- O modelo contribuirá para integrar soluções de reconhecimento de sinais de trânsito em sistemas de assistência ao condutor, como veículos autônomos e sistemas de segurança avançada, aumentando a segurança e eficiência nas estradas.

2. DESCRIÇÃO DAS METODOLOGIAS UTILIZADAS

Modelo Simples:

Uma abordagem direta, que não utiliza técnicas de otimização. Este programa foi treinado em um dataset com 5 classes, com 500 amostras cada.

Otimização por Random Search:

O Random Search é uma técnica de otimização de hiperparâmetros em modelos de machine learning. Escolhe combinações aleatórias dentro de um intervalo definido pelo utilizador.

3. ARQUITETURA DE CÓDIGO

```python
import pickle
import pandas as pd
import numpy as np
import tensorflow as tf
from sklearn.model_selection import train_test_split
from sklearn.metrics import confusion_matrix, accuracy_score, recall_score, precision_score, f1_score, roc_auc_score, classification_report
import seaborn as sns
import matplotlib.pyplot as plt
from tensorflow.keras.preprocessing.image import img_to_array, array_to_img
from tensorflow.keras.applications import MobileNetV2
from tensorflow.keras.models import Model
from tensorflow.keras.layers import Dense, GlobalAveragePooling2D, Dropout
from tensorflow.keras.optimizers import Adam
```

```python
def preprocess_data(file, target_size=(224, 224)):

    with open(file, 'rb') as f:
        data = pickle.load(f, encoding='latin1')
        x = data['features'].astype(np.float32)
        y = data['labels']
        sizes = data['sizes']
        coords = data['coords']

    df = pd.DataFrame({
        'features': list(x),
        'labels': y,
        'sizes': list(sizes),
        'coords': list(coords)
    })

    df_filtered = df[df['labels'].isin(classes)]

    df_limited = df_filtered.groupby('labels').apply(lambda x: x.sample(n=500, random_state=42)).reset_index(drop=True)
```

```python
# Pré-processamento
cropped_images = []
mapped_labels = []

for i in range(len(df_limited)):
    img = df_limited['features'].iloc[i]           # Imagem original
    x1, y1, x2, y2 = df_limited['coords'].iloc[i]
    width, height = df_limited['sizes'].iloc[i]    # Dimensões originais da imagem

    # Verificar que as coordenadas limitadoras estão dentro dos limites da imagem
    if x1 < 0: x1 = 0
    if y1 < 0: y1 = 0
    if x2 > width: x2 = width
    if y2 > height: y2 = height

    # Cortar a imagem pelos limites
    cropped_img = img[y1:y2, x1:x2, :]

    # Redimensionar a imagem para o tamanho esperado pela arquitetura
    img_resized = array_to_img(cropped_img).resize(target_size)
    img_resized = img_to_array(img_resized) / 255.0          # Normalizar

    # Guardar a imagem pré-processada
    cropped_images.append(img_resized)

    original_label = df_limited['labels'].iloc[i]
    mapped_labels.append(class_mapping[original_label])

# Converter listas para numpy arrays
cropped_images = np.array(cropped_images)
mapped_labels = np.array(mapped_labels)
```

3. ARQUITETURA DE CÓDIGO

```
# Dividir o conjunto de dados em treino e teste
X_train, X_test, y_train, y_test = train_test_split(cropped_images, mapped_labels, test_size=0.2, random_state=42, stratify=mapped_labels)

return X_train, X_test, y_train, y_test
```

```
def create_pretrained_model(input_shape, num_classes, learning_rate=0.001, dense_units=128):
    # Carregar o modelo MobileNetV2 pré-treinado no ImageNet
    base_model = MobileNetV2(weights='imagenet', include_top=False, input_shape=input_shape)

    # Congelar os pesos da base
    base_model.trainable = False

    # Adicionar camadas customizadas no topo (top layers)
    x = base_model.output
    x = GlobalAveragePooling2D()(x)
    x = Dense(dense_units, activation='relu')(x)
    x = Dropout(0.5)(x)  # Regularização com dropout
    x = Dense(dense_units // 2, activation='relu')(x)
    x = Dropout(0.5)(x)  # Regularização com dropout
    predictions = Dense(num_classes, activation='softmax')(x)

    # Criar o modelo final
    model = Model(inputs=base_model.input, outputs=predictions)

    # Compilar o modelo
    model.compile(optimizer=Adam(learning_rate=learning_rate),
                  loss='sparse_categorical_crossentropy',
                  metrics=['accuracy'])

    return model
```

```
input_shape = (224, 224, 3)  # Imagem 32x32 com 3 canais de cor (RGB)
num_classes = len(classes)

# Definir hiper-parâmetros
learning_rate = 0.001
dense_units = 256

pretrained_model = create_pretrained_model(input_shape, num_classes, learning_rate, dense_units)

pretrained_model.summary()

# Treinar o modelo
history = pretrained_model.fit(X_train, y_train, epochs=10, validation_data=(X_test, y_test), batch_size=32)

pretrained_model.save("traffic_sign_model.h5")
```

```
# Avaliar o modelo
test_loss, test_acc = pretrained_model.evaluate(X_test, y_test)
print(f'Test accuracy: {test_acc:.4f}')

y_probs = pretrained_model.predict(X_test)
y_pred = np.argmax(y_probs, axis=1)

# Calcular as Métricas
accuracy = accuracy_score(y_test, y_pred)
recall = recall_score(y_test, y_pred, average='weighted')
precision = precision_score(y_test, y_pred, average='weighted')
fmeasure = f1_score(y_test, y_pred, average='weighted')

# Exibir as métricas finais
print(f"Accuracy: {accuracy:.4f}")
print(f"Recall: {recall:.4f}")
print(f"Precision: {precision:.4f}")
print(f"F-measure: {fmeasure:.4f}")

# Calcular o AUC por classe
auc_scores = []
for i in range(num_classes):
    auc = roc_auc_score((y_test == i).astype(int), y_probs[:, i])
    auc_scores.append(auc)
    print(f"AUC for class {classes[i]}: {auc:.4f}")
```

3. ARQUITETURA DE CÓDIGO

```python
# Criar dataframes para salvar no Excel
df_results = pd.DataFrame({
    'Metric': ['Accuracy', 'Recall', 'Precision', 'F-measure'],
    'Value': [accuracy, recall, precision, fmeasure]
})

df_auc_scores = pd.DataFrame({
    'Class': classes,
    'AUC': auc_scores
})

df_confusion_mtx = pd.DataFrame(
    confusion_matrix(y_test, y_pred),
    index=[f"True_{cls}" for cls in classes],
    columns=[f"Pred_{cls}" for cls in classes]
)

# Criar um relatório de classificação detalhado
class_report = classification_report(y_test, y_pred, target_names=[f"Class_{cls}" for cls in classes], output_dict=True)
df_class_report = pd.DataFrame(class_report).transpose()

# Adicionar o tamanho das classes no conjunto de dados
df_shapes = pd.DataFrame({
    "Dataset": ["Training", "Testing"],
    "Samples": [X_train.shape[0], X_test.shape[0]],
    "Features Shape": [X_train.shape[1:], X_test.shape[1:]]
})
```

```python
# Matriz Confusão
cm = confusion_matrix(y_test, y_pred)
plt.figure(figsize=(10, 7))
sns.heatmap(cm, annot=True, fmt='d', cmap='Blues')
plt.xlabel('Predicted')
plt.ylabel('True')
plt.title('Confusion Matrix')
plt.show()

# Salvar todos os dados em um único arquivo Excel
with pd.ExcelWriter("model_results.xlsx") as writer:
    df_shapes.to_excel(writer, sheet_name='Formas dos Conjuntos', index=False)
    df_results.to_excel(writer, sheet_name='Resultados Otimizacao', index=False)
    df_auc_scores.to_excel(writer, sheet_name='AUC por Classe', index=False)
    df_confusion_mtx.to_excel(writer, sheet_name='Matriz de Confusão')
    df_class_report.to_excel(writer, sheet_name='Relatório de Classificação')
```

```python
# Plotar curvas de treino e validação
plt.figure(figsize=(12, 5))

# Curva de accuracy
plt.subplot(1, 2, 1)
plt.plot(history.history['accuracy'], label='Train Accuracy')
plt.plot(history.history['val_accuracy'], label='Validation Accuracy')
plt.title('Model Accuracy')
plt.xlabel('Epochs')
plt.ylabel('Accuracy')
plt.legend()

# Curva de perda
plt.subplot(1, 2, 2)
plt.plot(history.history['loss'], label='Train Loss')
plt.plot(history.history['val_loss'], label='Validation Loss')
plt.title('Model Loss')
plt.xlabel('Epochs')
plt.ylabel('Loss')
plt.legend()

plt.tight_layout()
plt.show()
```

4. APLICAÇÃO

```python
import streamlit as st
from PIL import Image
import numpy as np
import tensorflow as tf

# Carregar o modelo treinado (garanta que o modelo está no mesmo diretório do script)
@st.cache_resource
def load_model():
    model = tf.keras.models.load_model("traffic_sign_model.h5")
    return model
```

```python
# Função para processar a imagem e fazer a previsão
def predict(image, model):
    try:
        # Pré-processar a imagem
        img = image.convert("RGB")  # Converter para RGB
        img = img.resize((224, 224))  # Redimensionar para o tamanho esperado pelo modelo
        img_array = np.array(img) / 255.0  # Normalizar os valores de pixel
        img_array = np.expand_dims(img_array, axis=0)  # Adicionar dimensão batch

        # Fazer a previsão
        predictions = model.predict(img_array)
        predicted_class_idx = np.argmax(predictions[0])
        confidence = predictions[0][predicted_class_idx]

        return predicted_class_idx, confidence
    except Exception as e:
        st.error(f"Erro ao processar a imagem: {e}")
        return None, None
```

```python
# Dicionário de classes do modelo
classes = [2, 8, 9, 10, 11]
class_names = {
    0: "Sinal 2 - Speed limit (50km/h)",
    1: "Sinal 8 - Speed limit (120km/h)",
    2: "Sinal 9 - No passing",
    3: "Sinal 10 - No passing for vehicles over 3.5 metric tons",
    4: "Sinal 11 - Right-of-way at the next intersection",
}
```

```python
# Configurar título e descrição da página
st.title("Reconhecimento de Sinais de Trânsito")
st.write("Carregue uma imagem para classificar o sinal de trânsito utilizando o modelo treinado.")

# Carregar o modelo
model = load_model()

# Carregar a imagem
uploaded_image = st.file_uploader("Envie uma imagem no formato JPG ou PNG", type=["jpg", "jpeg", "png"])

if uploaded_image is not None:
    # Exibir a imagem carregada
    image = Image.open(uploaded_image)
    st.image(image, caption="Imagem carregada", use_container_width=True)

    # Botão para classificar a imagem
    if st.button("Classificar"):
        st.write("Classificando a imagem...")

        # Fazer a previsão
        with st.spinner("Processando..."):
            predicted_class_idx, confidence = predict(image, model)

        # Exibir os resultados
        if predicted_class_idx is not None:
            predicted_class = class_names.get(predicted_class_idx, "Classe desconhecida")
            st.success(f"Classe prevista: {predicted_class}")
            st.write(f"Confiança: {confidence:.4f}")
        else:
            st.error("Erro ao classificar a imagem. Verifique o formato ou tente novamente.")
```

5. DESCRIÇÃO DA IMPLEMENTAÇÃO DOS ALGORITMOS

```
X_train_flat = X_train.reshape(X_train.shape[0], -1)
X_test_flat = X_test.reshape(X_test.shape[0], -1)
```

```
param_grid = {
    'n_estimators': [10, 50, 100, 200],
    'max_depth': [5, 10, 20, None],
    'min_samples_split': [2, 5, 10],
    'min_samples_leaf': [1, 2, 4],
}
```

```
# Criar o modelo base para Random Forest
rf_model = RandomForestClassifier(random_state=42)

# Realizar Random Search
random_search = RandomizedSearchCV(rf_model, param_distributions=param_grid, n_iter=20, cv=3, verbose=2, random_state=42, n_jobs=-1)
random_search.fit(X_train_flat, y_train)

# Melhor modelo encontrado
best_rf = random_search.best_estimator_

# Avaliar o modelo Random Forest no conjunto de teste
rf_predictions = best_rf.predict(X_test_flat)
rf_accuracy = accuracy_score(y_test, rf_predictions)
rf_recall = recall_score(y_test, rf_predictions, average='weighted')
rf_precision = precision_score(y_test, rf_predictions, average='weighted')
rf_fmeasure = f1_score(y_test, rf_predictions, average='weighted')

print(f"Random Forest Accuracy: {rf_accuracy:.4f}")
print(f"Random Forest Recall: {rf_recall:.4f}")
print(f"Random Forest Precision: {rf_precision:.4f}")
print(f"Random Forest F-measure: {rf_fmeasure:.4f}")
```

6. ANÁLISE DOS RESULTADOS

Modelo Simples

Class	AUC
2	0,996775
8	0,9963
9	0,996825
10	0,994475
11	0,999975

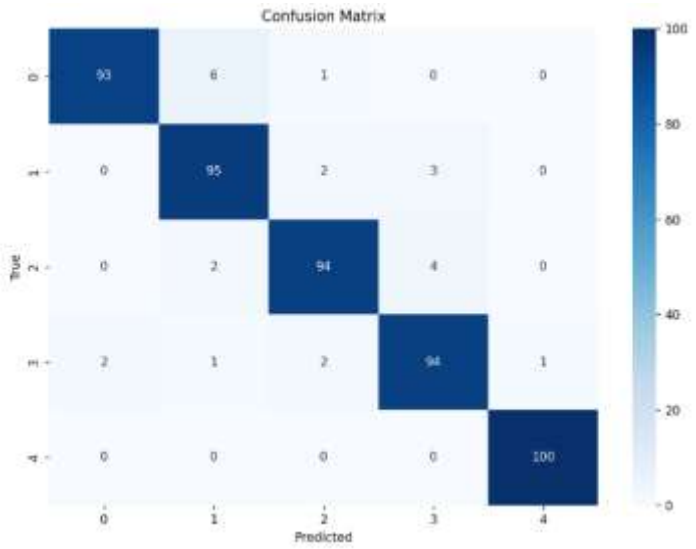

	precision	recall	f1-score	support
Class_2	0,978947	0,93	0,953846	100
Class_8	0,913462	0,95	0,931373	100
Class_9	0,949495	0,94	0,944724	100
Class_10	0,930693	0,94	0,935323	100
Class_11	0,990099	1	0,995025	100
accuracy	0,952	0,952	0,952	0,952
macro avg	0,952539	0,952	0,952058	500
weighted avg	0,952539	0,952	0,952058	500

	Pred_2	Pred_8	Pred_9	Pred_10	Pred_11
True_2	93	6	1	0	0
True_8	0	95	2	3	0
True_9	0	2	94	4	0
True_10	2	1	2	94	1
True_11	0	0	0	0	100

6. ANÁLISE DOS RESULTADOS

Random Search

Hiperparâmetros	Perda
{'dropout_rate': np.float64(0.46475886306307707), 'learning_rate': np.float64(0.010369442666219138)}	0,148999074
{'dropout_rate': np.float64(0.0907898114535644), 'learning_rate': np.float64(6.07169171990872e-05)}	0,612426519
{'dropout_rate': np.float64(0.3463425699764095), 'learning_rate': np.float64(0.004313719224595805)}	0,158498078
{'dropout_rate': np.float64(0.22857961444137093), 'learning_rate': np.float64(0.044601842475536065)}	0,15648407
{'dropout_rate': np.float64(0.4581471858024578), 'learning_rate': np.float64(0.003630678861289458)}	0,178996838
{'dropout_rate': np.float64(0.3117777229678997), 'learning_rate': np.float64(0.004764053218977656)}	0,153996575
{'dropout_rate': np.float64(0.39645511792317695), 'learning_rate': np.float64(0.026417472396234383)}	0,132502818
{'dropout_rate': np.float64(0.4452305322593182), 'learning_rate': np.float64(0.001597516901363555)}	0,231487109
{'dropout_rate': np.float64(0.37807854817412656), 'learning_rate': np.float64(0.003598166934707306)}	0,187000344
{'dropout_rate': np.float64(0.20962145653664688), 'learning_rate': np.float64(0.020059100286424568)}	0,132492312

	precision	recall	f1-score	support
2	0,945946	0,7	0,804598	100
8	0,72093	0,93	0,812227	100
9	0,945055	0,86	0,900524	100
10	0,886792	0,94	0,912621	100
11	1	1	1	100
accuracy	0,886	0,886	0,886	0,886
macro avg	0,899745	0,886	0,885994	500
eighted av	0,899745	0,886	0,885994	500

Classe	AUC
2	0,9789
8	0,965175
9	0,982025
10	0,991175
11	1

7. CONCLUSÕES

O projeto abordou a classificação de sinais de trânsito utilizando modelos de machine learning e otimização. O modelo inicial foi baseado na rede **MobileNetV2** pré-treinada, adaptada para o problema específico, com um pré-processamento de dados adequado e balanceado.

Técnicas Utilizadas:

- **Random Search** para otimização de hiperparâmetros, mas sem superar os resultados do modelo inicial.
- Avaliação do desempenho com **accuracy**, **precision**, **recall**, **f1-score** e **AUC**, mostrando um alto desempenho na classificação.

Resultados:

- A matriz de confusão indicou baixa taxa de erros de classificação, validando a robustez do modelo.
- **Streamlit** foi utilizado para criar uma interface gráfica, permitindo ao usuário carregar imagens e visualizar resultados de forma prática.

Conclusão:

A utilização de **redes neurais convolucionais** e **otimização de hiperparâmetros** mostrou-se eficaz para a classificação de sinais de trânsito, destacando a importância de um bom pré-processamento e avaliação rigorosa dos resultados.

5. REFERÊNCIAS

- Fichas Práticas de Inteligência Computacional;
- PDFs Teóricos de Inteligência Computacional;